

Deep learning Pytorch

Partie 12 : Le natural language processing



Présenté par **Morgan Gautherot**



Le Big Data


Seulement 21% de ces données sont structurées !

BIG DATA





Les catégories de données





Le traitement naturel du langage


Texte

Données non structurées




Data frame

Données structurées



Modélisation



Deep learning par la pratique

Leçon 2 : Les prétraitements classiques



Présenté par **Morgan Gautherot**



La tokenization

Transformer un texte en vecteur de mots

« Le machine learning est un apprentissage par minimisation de l'erreur ! »



['Le', 'machine', 'learning', 'est', 'un', 'apprentissage', 'par', 'minimisation', 'de', 'l'erreur', '!']



La normalisation

Suppression de la ponctuation, enlever les apostrophes, mettre en minuscule.

['Le', 'machine', 'learning', 'est', 'un', 'apprentissage', 'par', 'minimisation', 'de', 'l'erreur', '!']



['le', 'machine', 'learning', 'est', 'un', 'apprentissage', 'par', 'minimisation', 'de', 'le', 'erreur']



Les stop words

Les mots de liaison qui n'apportent pas de sens mais du bruit

['Le', 'machine', 'learning', 'est', 'un', 'apprentissage', 'par', 'minimisation', 'de', 'l'erreur', '!']



['machine', 'learning', 'apprentissage', 'minimisation', 'erreur']



Doublons

Plusieurs mots avec le même sens mais une orthographe différente.

« Julien est plus grand que toi, mais tu es plus grande que Sophie. Julien et Sophie sont plus grands que Marie. »



['grand', 'grande', 'grands']



Lemmatisation

Transformer un mot en son sens radical (lemme)

« Julien est plus grand que toi, mais tu es plus grande que Sophie. Julien et Sophie sont plus grands que Marie. »



['grand', 'grand', 'grand']



Stemming

Supprimer la fin des mots

« Julien est plus grand que toi, mais tu es plus grande que Sophie. Julien et Sophie sont plus grands que Marie. »



['gran', 'gran', 'gran']



Résumé

- Tokenization
- Normalisation
- Suppression des stop words
- Lemmatisation / Stemming

Deep learning par la pratique

Leçon 3 : Bag of words



Présenté par **Morgan Gautherot**



Le vecteur de vocabulaire

$$V = \begin{bmatrix} arachide \\ \vdots \\ bain \\ \vdots \\ voiture \\ \vdots \\ zumba \end{bmatrix}$$



D'une phrase à un bag of words

Doc 1

Le thé est bouillant



Traitements du texte

Doc 1

['thé', 'être', 'bouillant']



Transformation en bag of words

$V = [arachide, \dots, bain, bouillant, \dots, être, \dots, thé, \dots, voiture, \dots, zumba]$

$D_1 = [\quad 0, \dots, \quad 0, \quad 1, \dots, \quad 1, \dots, \quad 1, \dots, \quad 0, \dots, \quad 0]$



Tu me donnes envie de faire table rase du passé, et de t'isoler à faire table rase du tien. Tu me donnes envie d'être pour toi ce que je n'ai jamais tu être pour quelqu'un d'autre. Tu me donnes envie de t'offrir mon cœur, mes ambitions, mon amour sur un plateau d'argent. Tu me donnes envie de t'aimer à en faire trembler le monde entier. Tu me donnes envie de parler de sentiments et de bonheur tout en conjuguant mes verbes au présent. Tu me donnes envie de devenir quelqu'un qui t'apportera rêves et douceur. Tu me donnes envie de décrocher la lune, de te faire un monde. Tu me donnes envie de vivre, border. Parce que tu es l'écume au fond de mes yeux, mon sourire terriblement sincère. Parce que je ne suis plus seule désormais, tu es là. Et c'est si précieux.

$$= D_1$$

006

L'AMITIÉ

L'amitié est un repère,
une ligne d'horizon. Une lumière
et une porte secrète vers les émotions...
Elle nous aide par temps durs, elle fait rire,
elle rassure. Elle ne juge pas, elle accepte,
elle est là... Tantôt près, tantôt loin,
mais toujours à distance de coeurs, notre
amitié c'est du bonheur. Notre amitié, c'est
une plante que je cultive avec grands soins,
le trésor de mon péri-jardin. Une pierre
précieuse qui m'éclaire dans le noir, et
quelqu'un qui connaît toute mon histoire...
J'avance sur mon chemin, tu avances sur
le tien. L'horizon devant nous est infini,
tout comme notre amitié, merci.

$$= D_3$$

Sophie fait *des courses au supermarché* avec son *meu* Clément. Après avoir *soigné sa voiture* sur la parking, elle a *pris un choriot* dans lequel Clément *était installé*. Tous deux *parcourent* maintenant dans le magasin. Les clients *se rendent* à la caisse des *productions et des solides*. Sophie *est* à la *liste des courses* pour ne *rien oublier*. Elle *regarde les marques* et compare les *prix*. Elle *choisit des produits frais*, des *comestibles* et du *position agricole* qu'elle met dans son *panier*. Elle *se dirige* vers la *tablette* pour *acheter* les *produits* qu'elle *recueille* des *habitants*, des *biscuits*, et *des jus*, *des fruits*. Sophie *garde* le *grand germinet* pour elle, *regarde* sa *marque*, et *est déjà* *sauve* *heure*. Elle *donne* au *lithier* de *rentrer* car *son* *ami* *est* *installé* avec. *Jeau* dit *à-dire* *chac* le *nom* de Clément, *son* *meu* Lucie. Sophie *termine* les *courses*, elle *se dirige* vers la *caisse* où elle *attend* *calmement* son *tour*. A la *caisse*, elle *place* ses *achats* sur le *tableau* où elle *regarde* la *liste* des *courses* pour ne *rien oublier* et *se* *convoque*. A *présent*, elle *regarde* la *panier*, *regarde* *quelques* *marques* *et* *se* *dirige* vers la *tablette*. Elle *regarde* au *dessus* de la *tablette* pour *se* *diriger* vers le *tableau* où elle *regarde* la *liste* des *courses* pour ne *rien oublier*. Elle *installe* Clément dans son *siège* pour *acheter* les *produits*. Elle *part* *retourner* *Jeau* et *se* *convoque* *la* *marque*.

$$= D_2$$
[illegible]
$$= D_4$$

V	D_1	D_2	D_3	D_4	$\dots$	D_n
mot_1	0	1	0	0	$\dots$	0
mot_2	0	0	0	1	$\dots$	0
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
mot_m	0	1	0	0	0	0

Deep learning par la pratique

Leçon 4 : TF-IDF



Présenté par **Morgan Gautherot**



Définition du TF-IDF

TF = Term Frequency

IDF = Inverse Document Frequency



Term Frequency

$$tf_{w,d} = \frac{n_{w,d}}{\sum_k n_{k,d}}$$

d est un document de notre jeu de données

w est un mot de notre document

$n_{w,d}$ est le nombre d'occurrences du mot w du document d



Inverse Document Frequency

$$idf_w = \log\left(\frac{|D|}{f(w, D)}\right)$$

D désigne tous les documents de notre jeu de données

w est un mot de notre document

$f(w, D)$ est le nombre de document D contenant le mot w



Calcul du TF-IDF

$$tf.idf_{w,d} = tf_{w,d} * idf_w$$

$$tf.idf_{w,d} = \frac{\text{fréquence du terme dans le document}}{\text{fréquence du terme dans le corpus}}$$





Vecteur de vocabulaire

$$V = \begin{bmatrix} arachide \\ \vdots \\ bain \\ \vdots \\ voiture \\ \vdots \\ zumba \end{bmatrix}$$



D'une phrase à un vecteur





Le supermarché

Sophie fait ses courses au supermarché avec son nouveau Clément. Après avoir sorti du véhicule sur le parking, elle se prend un chariot dans lequel Clément est installé. Tous deux s'élèvent maintenant dans le magasin. Les clients ont remarqué à cause des coups de frein et des solides. Sophie sort à la suite des courses pour ne rien oublier. Elle regarde les marques et compare les prix. Elle choisit des produits frais, des conserves et du poisson congelé qu'elle met dans son chariot. Clément est turbulente, il s'agite sur son siège, il se lève quand le réfrigérateur est ouvert. Sophie se penche vers lui et dit : « Tu es fatigué ? Le magasin te gêne-t-il ? regarde ou même, si tu as déjà assez bu ». Elle doit se hâter de rentrer car sa mère est allée invitée chez Jean d'être chez le nonon de Clément, sa tante Lucie. Sophie termine les courses, elle se dirige vers la caisse où elle attend calmement son tour. À la caisse, elle place ses achats sur le tapis roulant puis elle règle en numéraire ce qu'elle doit.

Elle repart, elle regagne le parking, cherche quelques minutes son véhicule. Elle le repère au fond de l'allée mais se dirige vers une autre voiture qui se trouve devant elle. Elle aperçoit une jeune fille, Clément dans son siège par la fenêtre. Elle portait restrainer. Deux-ils ne s'arrêtent pas la parole.

$$= D_1$$

Doc 3

006

L'AMITIÉ

L'amitié est un repère,
une ligne d'horizon. Une lumière
et une porte secrète vers les émotions...
Elle nous aide par temps durs, elle fait rire,
elle rassure. Elle ne juge pas, elle accepte,
elle est là... Tantôt près, tantôt loin,
mais toujours à distance de coeurs, notre
amitié c'est du bonheur. Notre amitié, c'est
une plante que je cultive avec grands soins,
le trésor de mon petit jardin. Une pierre
précieuse qui m'éclaire dans le noir, et
quelque un qui connaît toute mon histoire...
J'avance sur mon chemin, tu avances sur
le tien. L'horizon devant nous est infini,
tout comme notre amitié, merci.

$$= D_3$$

Doc 2

$$= D_2$$

Doc 4

$$= D_4$$
[illegible]

V	D_1	D_2	D_3	D_4	$\dots$	D_n
mot_1	0	$tf.idf_{mot_1}$	0	0	$\dots$	0
mot_2	0	0	0	$tf.idf_{mot_2}$	$\dots$	0
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
mot_m	0	$tf.idf_{mot_1}$	0	0	0	0