

Deep learning avec Pytorch

Partie 14 : Les Transformers



Presented by **Morgan Gautherot**

Des RNN aux Transformers




Partie 10 : Les Transformers



L'influence des premiers termes

I like to study machine learning _____





Traduction

How are you today ?




Wie geht es Ihnen heute ?






Seq2seq model (Google 2014)






Le bottleneck de l'information



Plus la taille de la séquence augmente, plus les performances du modèle diminuent !




Alignement des mots






Quel est le mot auquel il faut prêter le plus d'attention ?






Quel est le mot auquel il faut prêter le plus d'attention ?






Plus de poids = plus d'attention





Plus de poids = plus d'attention






Transformer

Plus rapide que le RNN

Profondément bidirectionnel






Transformer

This
is
amazing




<start>





Du transformer à l'embedding



Qu'est-ce que l'anglais ? Qu'est-ce que le contexte ?

Comprendre la langue

Comment faire correspondre des mots anglais aux mots français

Comprendre la langue

Comprendre les transformateurs



Partie 10 : Les Transformers



Traduction anglais - espagnol

Let's go



vamos



Bag of words

V [let's, to, go, <EOS>]

Let's [1, 0, 0, 0]

go [0, 0, 1, 0]





Bag of words

V [ir, vamos, y, <EOS>]

vamos [0, 1, 0, 0]




Word embeddings





Transformer





L'ordre des mots

Il est très important de respecter l'ordre des mots

Cats eat fish



!=

Fish eat cats





Encodage positionnel

Valeur positionnelle unique





Positional encoding





L'ordre des mots

Cats eat fish

0.2 0.9 1.2 0.6 1.45 0.95 -0.5 1.70 0.70 -1.9 0.9 0.45



!=

Fish eat cats

0.70 -1.9 0.9 0.45 1.45 0.95 -0.5 1.70 0.2 0.9 1.2 0.6




Encodage positionnel





Transformer






Self attention

The **pizza** came out of the **oven** and **it** tasted good!





Calcul de la similarité





Calcul de la similarité

Une fois les similitudes calculées, elles sont utilisées pour déterminer comment le transformateur code chaque mot

The pizza came out of the oven and it tasted good!




Self attention

The **pizza** came out of the **oven** and **it** tasted good!




Nous pouvons considérer la sortie de la fonction softmax comme un moyen de déterminer le pourcentage d'utilisation de chaque mot pour encoder le mot « Let's ».

Détail du self-attention





Détail du self-attention






Les avantages de l'auto-attention chez les transformateurs

- Les Transformers utilisent un seul ensemble de poids pour calculer les requêtes d'auto-attention, quel que soit le nombre de mots en entrée
- Les Transformers peuvent calculer les requêtes, les Keys et les valeurs pour chaque mot en même temps.





Transformer



Les connexions résiduelles facilitent l'entraînement de réseaux neuronaux complexes en permettant à la couche d'auto-attention d'établir des relations entre les mots en entrée sans avoir à préserver également les informations relatives à l'embedding des mots et à l'encodage de la position.




Les connexions résiduelles







Transformer







Decoder

Encoder






Codage positionnel






Détail du self-attention






Détail du self-attention





Connections résiduelles






Attention entre l'encoder et le decoder

The **pizza** came out of the **oven** and **it** tasted good!

Nous avons parlé de la façon dont le self-attention aide le transformer à suivre les relations entre les mots d'une même phrase. Cependant, puisque nous traduisons une phrase, nous devons également tenir compte des relations entre la phrase d'entrée et la phrase de sortie.





Attention entre l'encoder et le decoder

Don't eat the delicious looking and smelling pizza





Eat the delicious looking and smelling pizza




Attention entre l'encoder et le decoder

Encoder






Attention entre l'encoder et le decoder







Attention entre l'encoder et le decoder






Attention entre l'encoder et le decoder



L'ajout d'une connexion résiduelle permet à l'attention du codeur-décodeur de se concentrer sur les relations entre les mots de sortie et l'entrée sans avoir à préserver le self-attention ou l'embedding du mot et de la position qui a eu lieu précédemment.





Transformer






Fully connected layer






Transformer





Fully connected layer

Encoder



Decoder

